Enfermedad cardiaca: factores de riesgo y modelos predictivos

Metodología CRISP-DM · Encuesta BRFSS 2015 (CDC) · 229.781 registros sin duplicados

Fuente: Heart Disease Health Indicators (alexteboul), Kaggle, licencia CC0.

1. Comprensión del negocio

Pregunta: ¿qué factores de salud y hábitos se asocian con infarto o enfermedad cardiaca, y qué tan bien se puede estimar ese riesgo para apoyar la prevención?

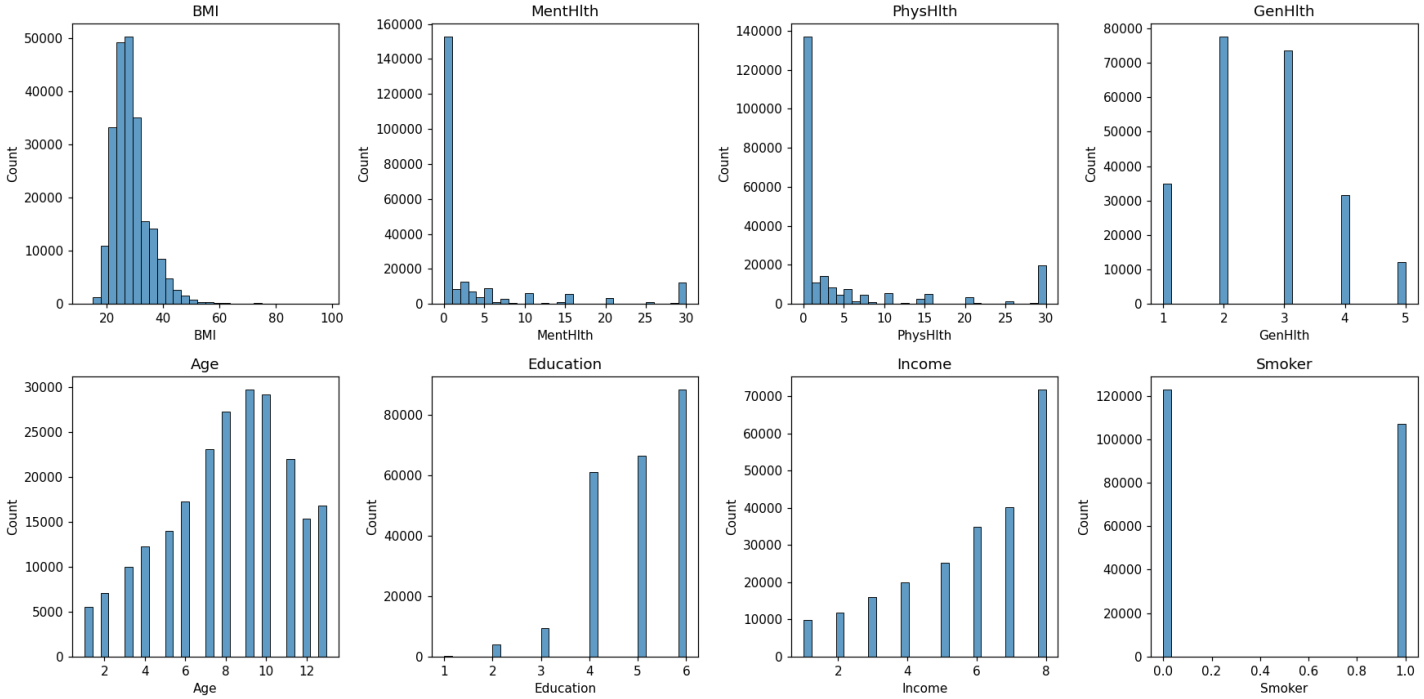
Límite del estudio: datos autoreportados y de corte transversal. Muestran asociaciones, no causas.

2. Comprensión y preparación de los datos

253.680 registros originales; 23.899 duplicados exactos eliminados; 229.781 registros finales. Sin nulos. Evento en 10,3 % (desbalance).

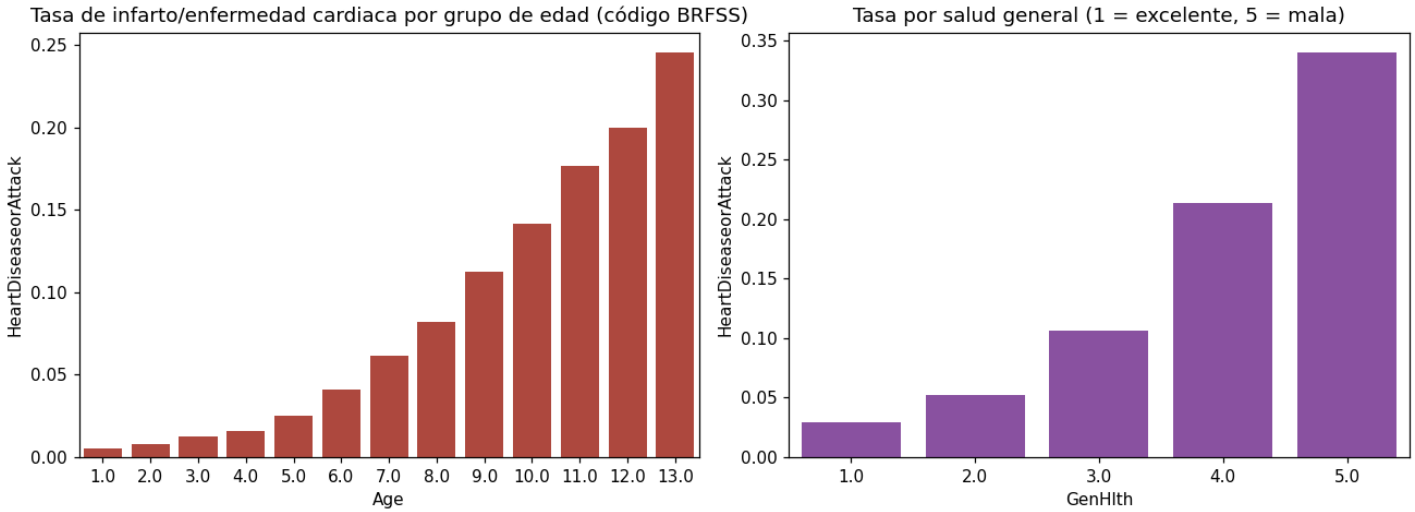
Codificación: binarias 0/1; ordinales (edad, salud general, educación, ingreso, diabetes) conservadas como enteros para respetar su orden. Normalización: StandardScaler solo para regresión logística, ajustado con entrenamiento.

2.1 Distribuciones



Distribución de variables numéricas tras la limpieza.

2.2 Tasa de evento por edad y salud general



La tasa sube de 0,5 % (grupo 1) a 24,6 % (grupo 13).

3. Modelamiento y evaluación

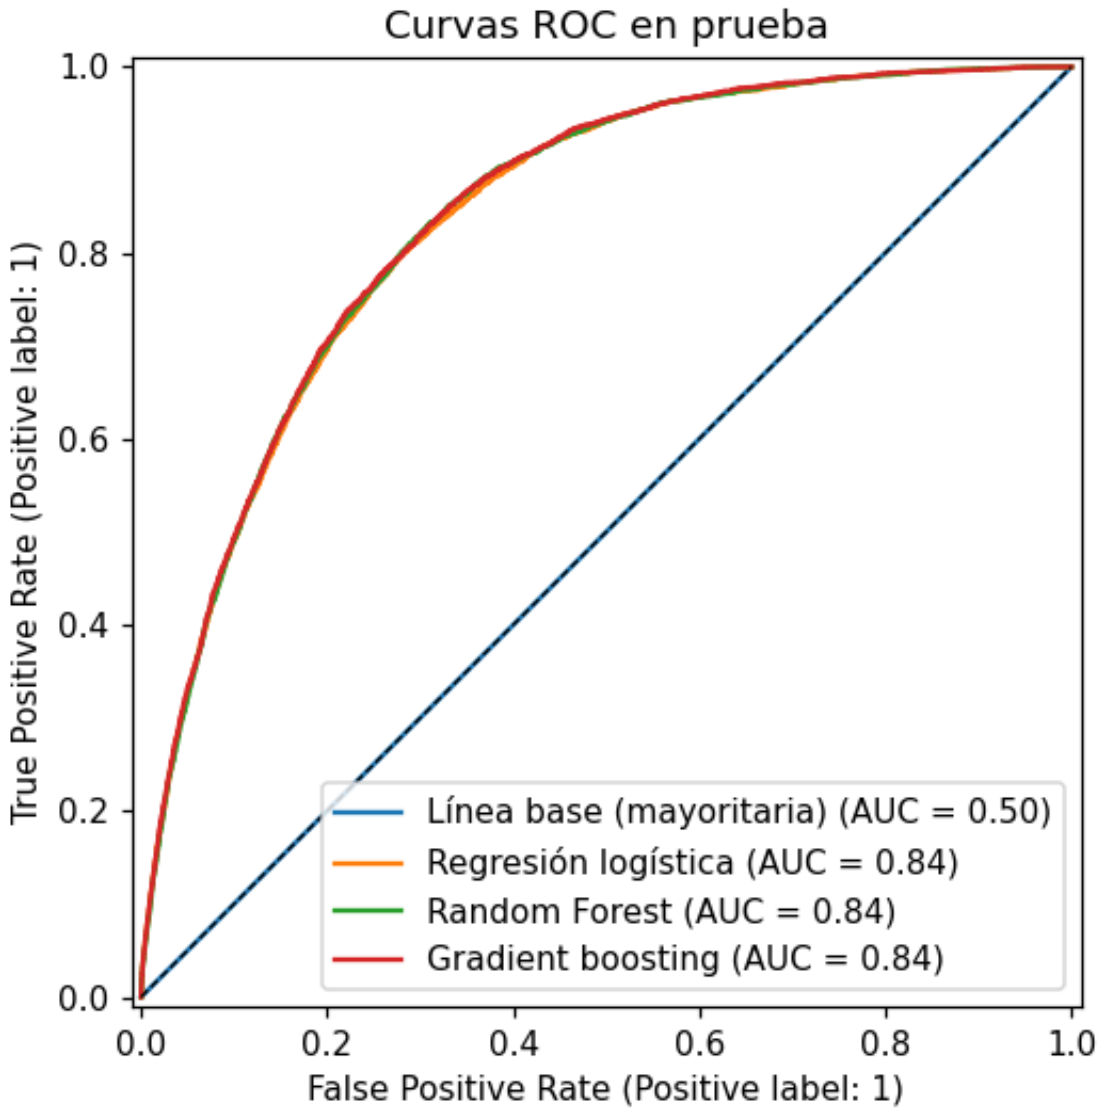
Validación cruzada de 5 folds (entrenamiento):

modelo	cv_roc_auc	cv_roc_auc_std	cv_pr_auc	cv_f1
Línea base (mayoritaria)	0.5	0.0	0.1032	0.0
Regresión logística	0.8356	0.0025	0.3727	0.3834
Random Forest	0.8364	0.0029	0.3743	0.3814
Gradient boosting	0.8375	0.0025	0.3776	0.3785

Prueba (20 %, 45.957 registros):

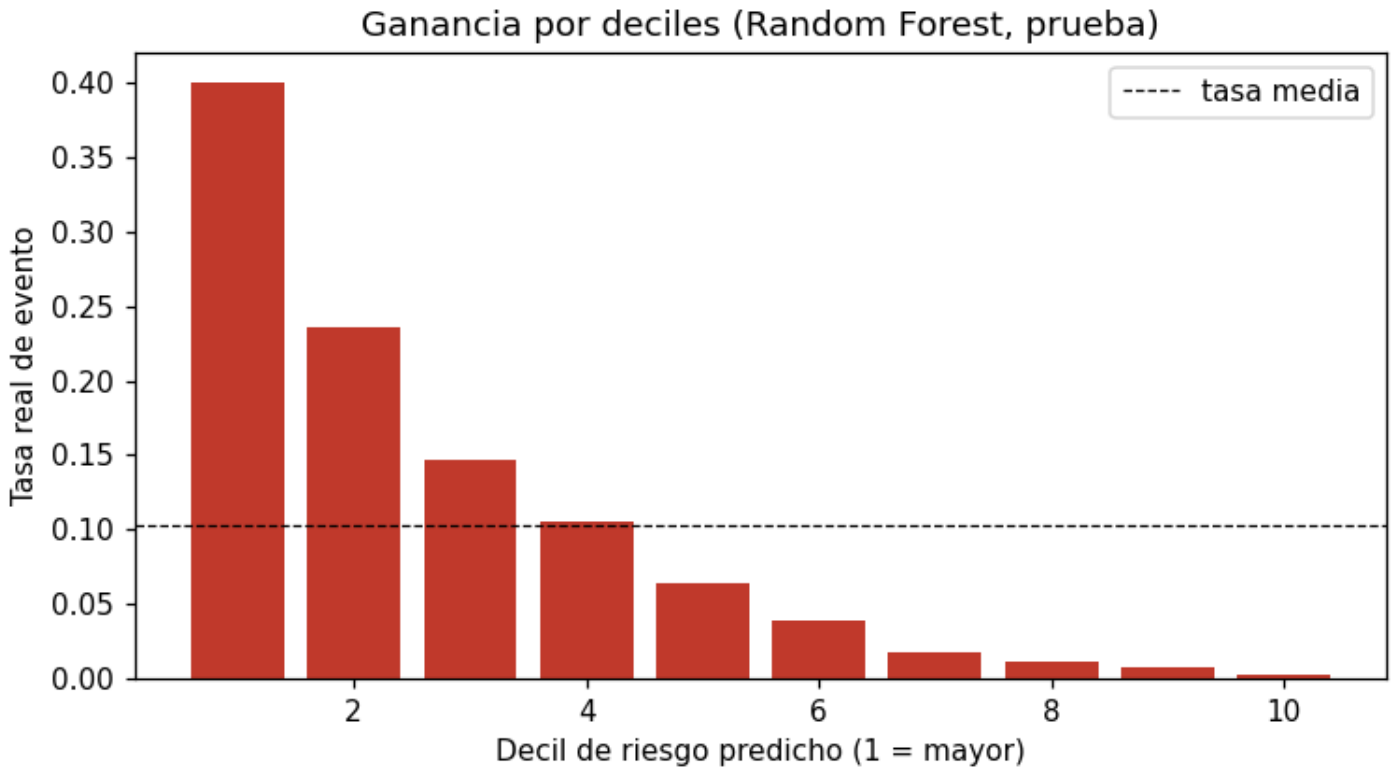
modelo	roc_auc	pr_auc	precision_umbral_0.5	recall_umbral_0.5	f1_umbral_0.5
Línea base (mayoritaria)	0.5	0.1032	0.0	0.0	0.0
Regresión logística	0.8355	0.3725	0.2524	0.7782	0.3811
Random Forest	0.8369	0.3714	0.2489	0.7944	0.3791
Gradient boosting	0.8383	0.3767	0.2455	0.8014	0.3759

3.1 Curvas ROC en prueba



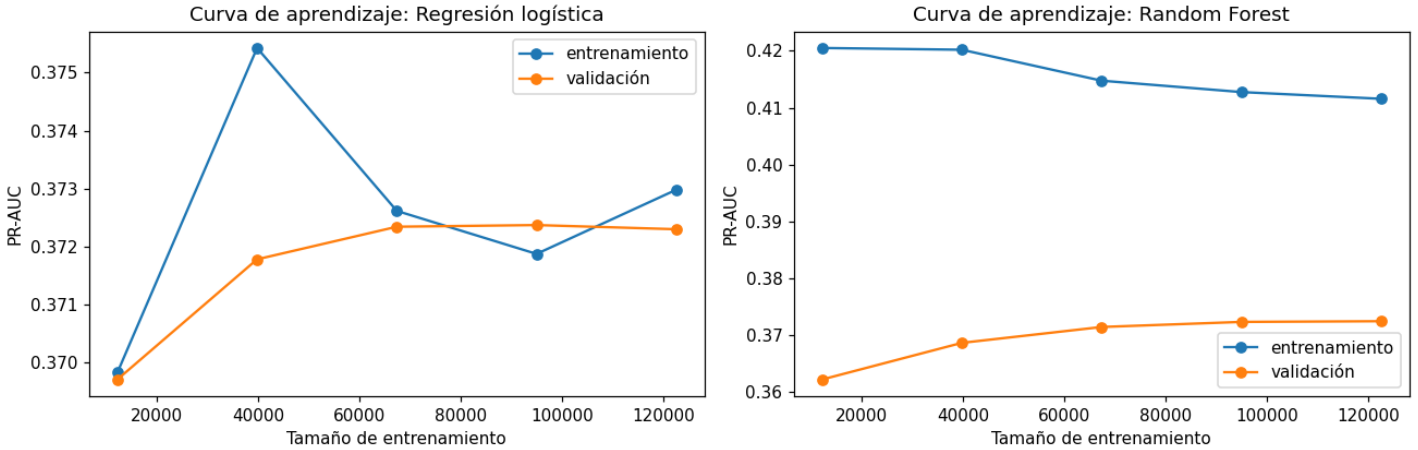
Todos los modelos superan la línea base (AUC 0,50).

3.2 Ganancia por deciles (Random Forest)



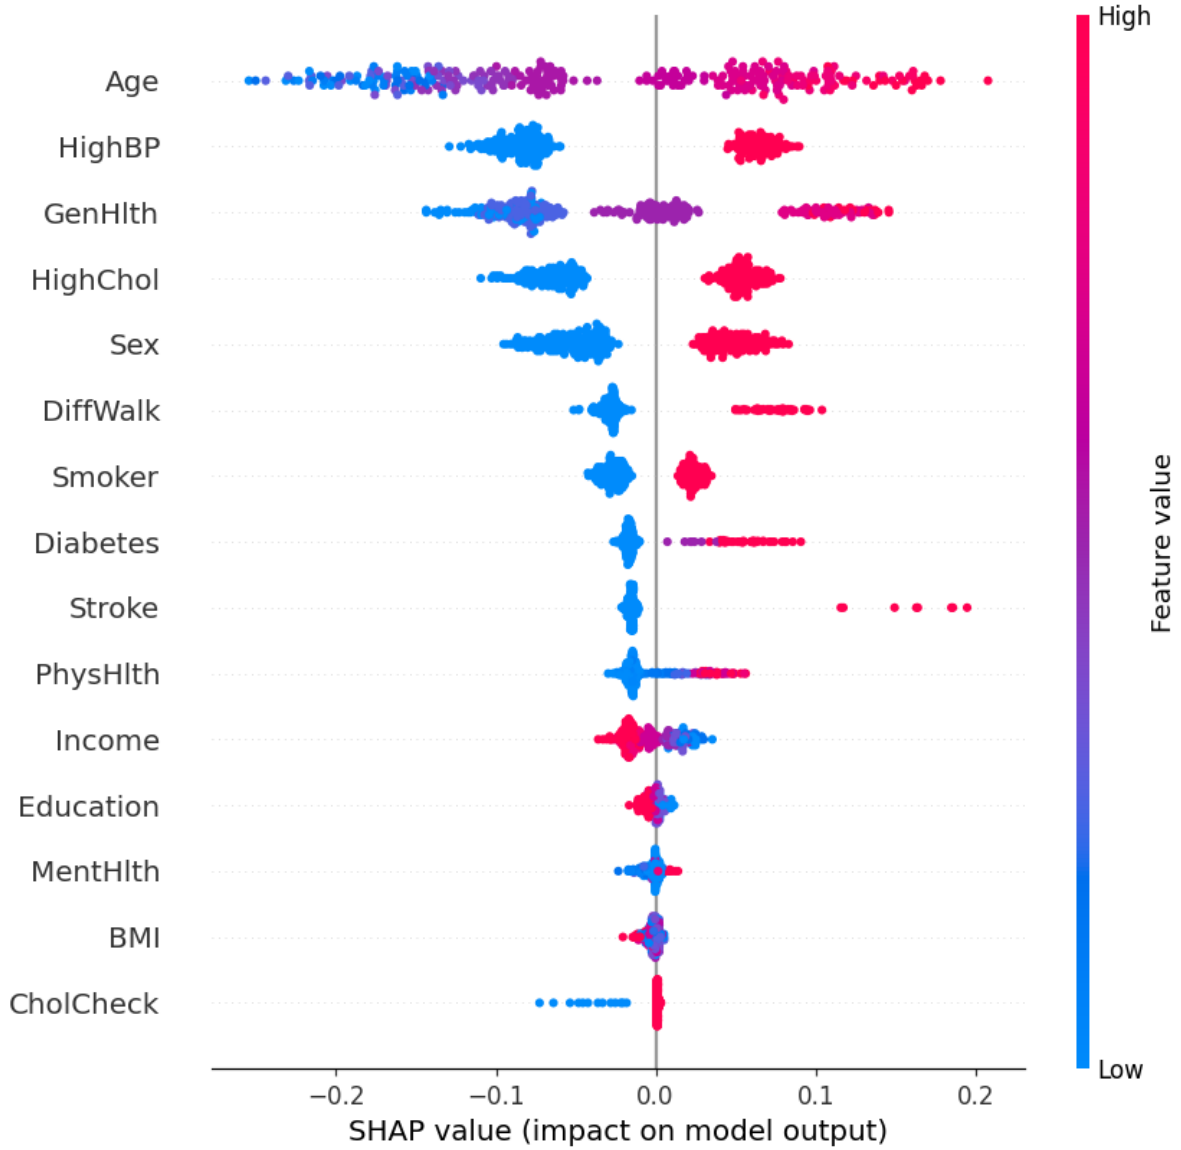
El decil de mayor riesgo predicho concentra la mayor tasa de evento.

3.3 Curvas de aprendizaje



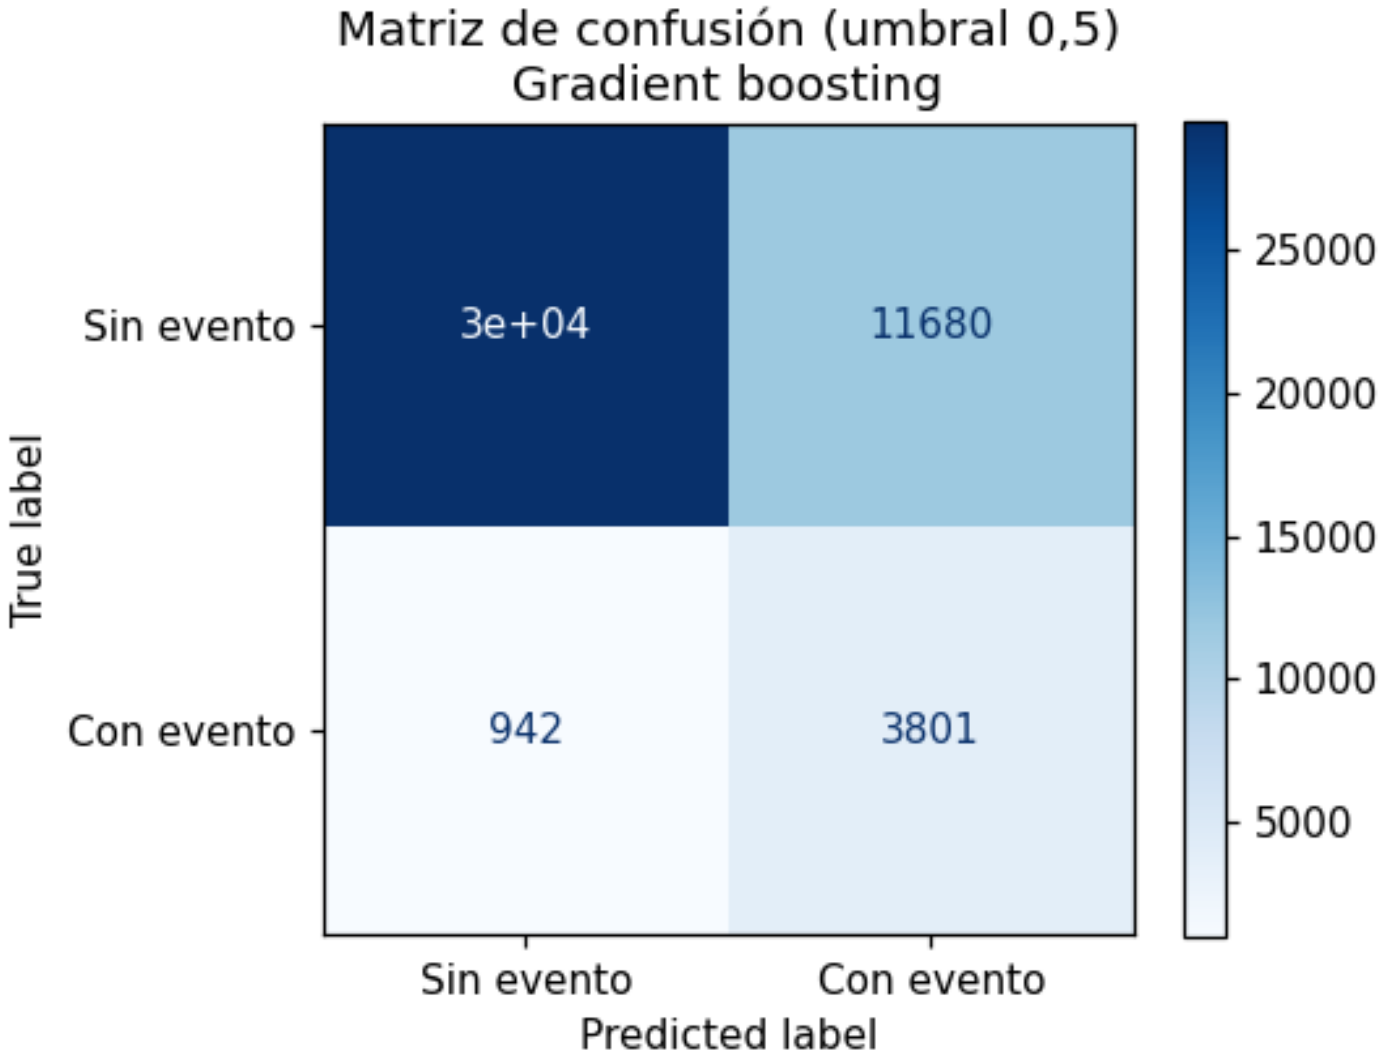
Brecha entre entrenamiento y validación: diagnóstico de sobreajuste.

3.4 Explicabilidad (SHAP, Random Forest)



Valores SHAP de una muestra de 300 registros de prueba.

3.5 Matriz de confusión (umbral 0,5)



Gradient boosting con umbral 0,5: detecta ~80 % de los casos (3.801 de 4.743), con precisión ~25 %.

3.6 Robustez: intervalos de confianza

Bootstrap sobre el conjunto de prueba, 1.000 remuestreos. Los intervalos se traslapan: la diferencia entre modelos no es distinguible.

Modelo	Métrica	Valor	IC 95 % (bootstrap)
Regresión logística	ROC-AUC	0.8355	0.8300 a 0.8407
Regresión logística	PR-AUC	0.3725	0.3597 a 0.3873
Random Forest	ROC-AUC	0.8369	0.8314 a 0.8420
Random Forest	PR-AUC	0.3714	0.3575 a 0.3857

3.7 Equidad: métricas por sexo y edad

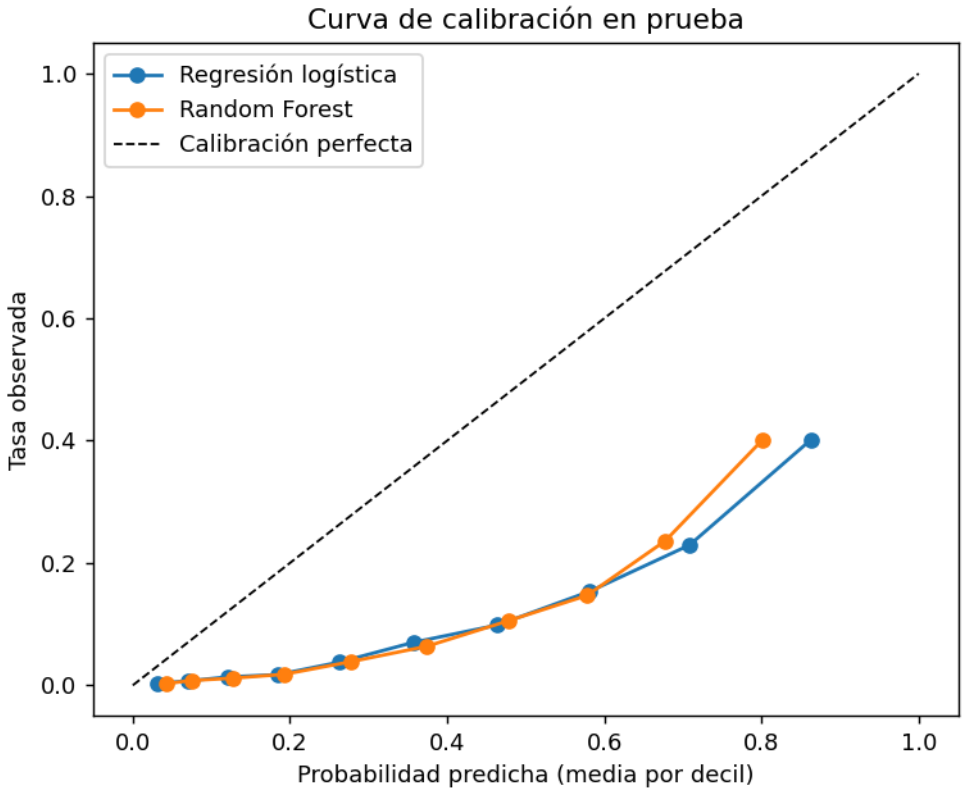
Umbral 0,5. El recall es mayor en mujeres y en mayores de 65, pero la precisión es menor. El ROC-AUC en mayores de 65 es cercano a 0,76.

Modelo	Grupo	n	ROC-AUC	Recall	Precisión
Regresión logística	Sexo: hombre (1)	20239	0.822	0.8321	0.268
Regresión logística	Sexo: mujer (0)	25718	0.8366	0.7067	0.2313
Regresión logística	Edad: 65 años o más (código 10 a 13)	16620	0.7552	0.8719	0.2649
Regresión logística	Edad: menores de 65 (código 1 a 9)	29337	0.8479	0.6081	0.2247
Random Forest	Sexo: hombre (1)	20239	0.8238	0.8421	0.2695
Random Forest	Sexo: mujer (0)	25718	0.8376	0.7312	0.2229
Random Forest	Edad: 65 años o más (código 10 a 13)	16620	0.7574	0.8807	0.2638
Random Forest	Edad: menores de 65 (código 1 a 9)	29337	0.8499	0.6378	0.218

3.8 Calibración de las probabilidades

Las probabilidades no están calibradas: su promedio es cercano a 0,36 frente a una prevalencia de 0,10 por el efecto de class_weight='balanced'. Sirven para ordenar el riesgo, no como probabilidad absoluta.

Modelo	Brier	Prob. media predicha	Prevalencia observada
Regresión logística	0.1709	0.3643	0.1032
Random Forest	0.1654	0.3623	0.1032



4. Conclusiones y recomendaciones

• Edad y salud general son los factores más asociados al evento.

• Regresión logística y Random Forest rinden casi igual (AUC ≈ 0,84). La regresión es más simple de explicar.

• El umbral debe elegirse según el costo de falsos positivos frente a falsos negativos en la prevención.

• Equidad y calibración: el modelo no rinde igual por grupo y sus probabilidades no son absolutas. Revisar antes de usarlo.

• Limitaciones: datos autoreportados, sin búsqueda de hiperparámetros y sin validación externa.